2025-04-03汇报

基于智能体的自动化渗透测试研究

文献阅读=>PentestAgent=>基于LLM的自动化渗透测试框架

1. 研究对象

- **研究背景**：传统渗透测试依赖人工专家，耗时且成本高，而现有自动化方法（如基于MDP或强化学习的框架）在灵活性、适应性和实施上存在不足
- **具体对象**：目前LLM主要用于改进内部评估，外部较少，因此本文针对**以客户端为主的外部评估（如Web应用程序、服务为目标）**

2. 研究目的

目标：通过LLM增强的多智能体协作，构建端到端的自动化渗透测试框架，减少人工参与，提升效率和成功率

- **解决现有问题=>LLM应用于渗透测试的挑战**：
  - **知识局限**：传统LLM在渗透测试领域的知识覆盖不足（如CVE漏洞库、特定工具链）
  - **短期记忆**：由于上下文窗口的限制，模型可能会忘记之前的操作，导致执行冗余的**重复任务**，或出现**上下文丢失**，模型无法提供执行漏洞利用的详细说明
  - **自动化不足**：现有工具依赖人工干预，难以动态适应复杂环境（如防御机制变化）
  - **工作流集成**：
    - **输出质量控制**：要求LLM以符合预定义标准或协议的结构化格式生成输出
    - **有状态工作记忆管理**：每个阶段通常需要**不同的状态工作记忆集**，包括漏洞发现、漏洞选择、目标环境细节、上下文信息等，如何实现平稳过渡

3. 具体流程

- **技术实现**
  - **LLM代理**：配备额外工具的LLM，如：可以在线搜索和学习渗透测试知识，解决**知识局限**的问题；
  - **RAG增强技术**：
    - **索引（Indexing）**：将外部知识库（如文档、数据库）转化为高效检索的结构化表示
    - **检索（Retrieval）**：根据用户输入的查询，从索引中快速定位最相关的知识片段，动态补充模型上下文，解决**短期记忆**问题
    - **响应合成（Response Synthesis）**：将检索到的信息与原始查询结合，生成最终回答，有效支持与维护**有状态工作记忆管理**
  - **多智能体协作**：各智能体分工明确，通过结构化输出和状态管理实现流程衔接
  - **思维链CoT（Chain of Thought）**：将复杂问题拆解为多个中间步骤，为每个工作流程指定一个**停止条件**以避免各智能体进入无限循环
  - **自适应的执行流程**：要求LLM进行**角色扮演**，有明确目标以及边界操作；同时引入**自反思机制**，通过LLM对失败任务进行分析并生成备选方案，同时通过**JSON格式约束输出**，减少随机性和错误传播
- **框架设计**：四个组件执行三个主要阶段
  - **情报收集（Reconnaissance Agent）**：**侦察代理**收集有关目标主机的环境信息，编译目标环境摘要，存储在环境信息数据库中
  - **漏洞分析（Search & Planning Agent）**：
    - **搜索代理**查询环境信息数据库以检索目标主机上暴露的服务和应用程序列表，搜索潜在的攻击面和程序
    - **计划代理**利用RAG技术来查找潜在攻击面列表，确定目标环境的合适漏洞利用以及攻击计划
  - **漏洞利用（Execution Agent）**：**执行代理**尝试在目标主机上执行攻击计划，生成与记录全面的渗透测试报告

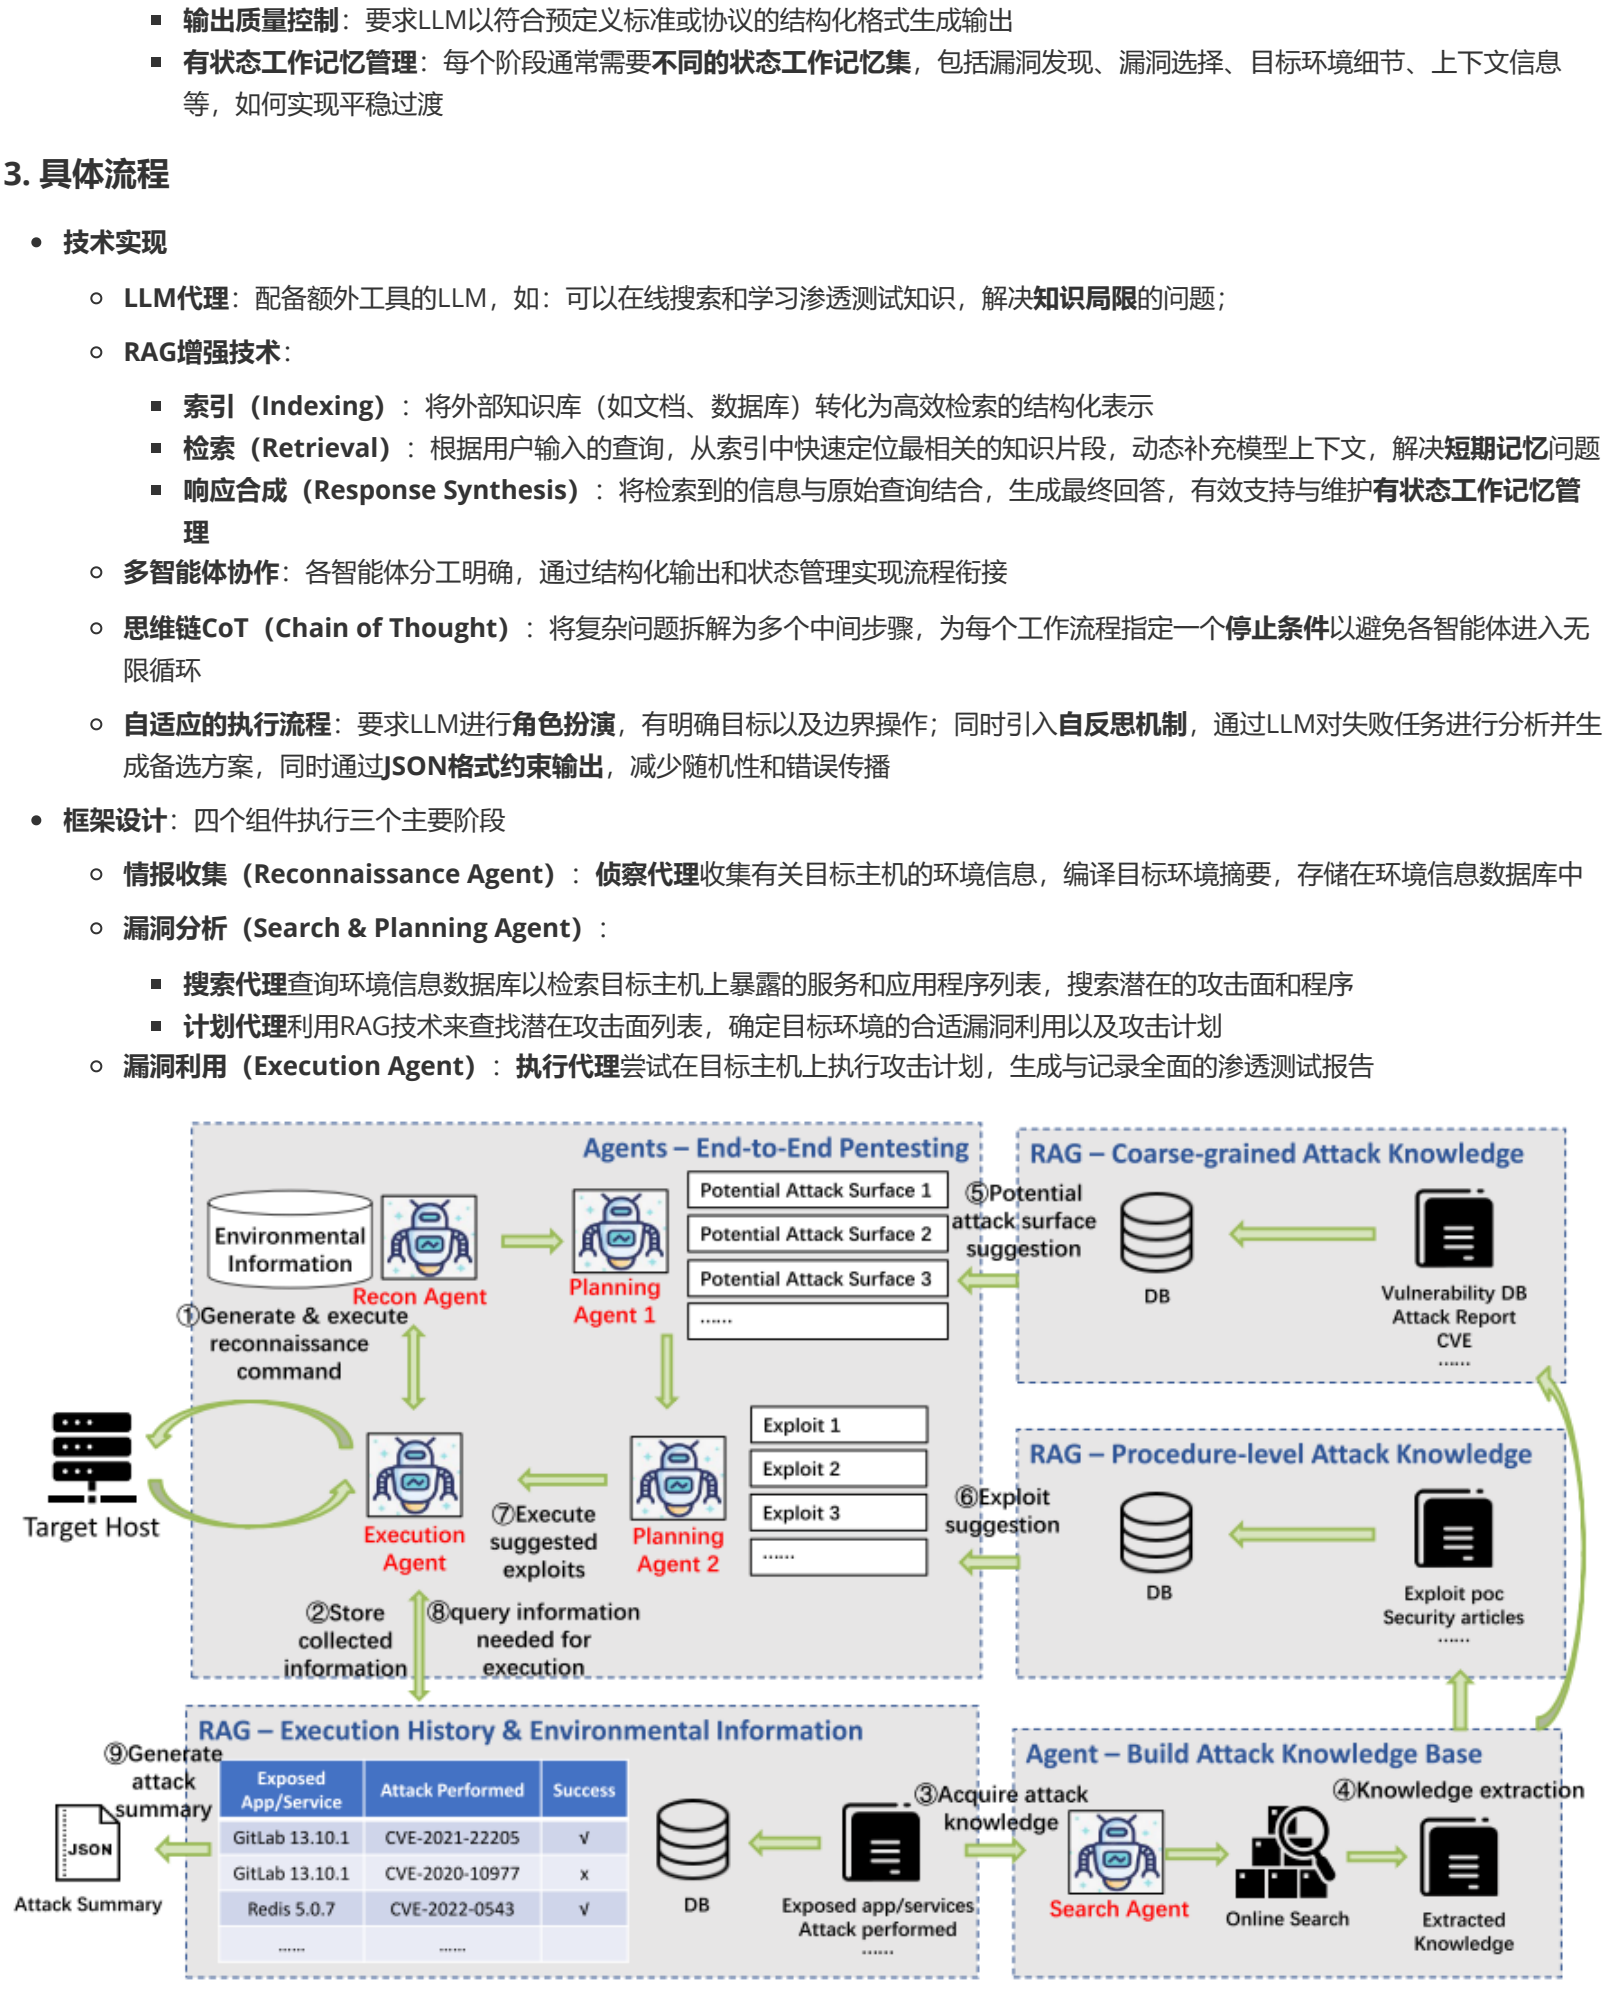

4. 实验设置

- **受害者机器**：在Ubuntu 22.04 LTS上运行模拟的易受攻击应用程序，禁用所有需要在端口上监听的服务，比如SSH
- **攻击者机器**：在Kali Linux 2024.1上运行，包括Kali Linux中可用的所有预安装工具，没有安装其他工具
- **LLM模型**：我们使用OpenAI GPT-3.5和GPT-4模型

两者通过**NAT**保持网络连接，在受害者机器上创建易受攻击的容器，并将网络参数设置为受害者机器的IP，允许攻击者机器直接访问受害者机器容器中托管的易受攻击环境

5. 研究方向的拓展

- **因果推理与攻击链优化**：
  - **问题**：现有攻击链生成依赖概率推断，缺乏因果逻辑支持，可能导致低效或不可行的路径选择
  - **方案**：引入因果图模型（Causal Graph），基于因果关系优先选择高概率且可行的攻击路径，提升攻击链的合理性和成功率
- **记忆增强的长期规划**：
  - **挑战**：LLM的上下文窗口限制导致历史经验无法有效存储，影响长期任务的连贯性
  - **解决**：设计高效的外部记忆库，结合记忆蒸馏技术**优化存储**，防止**记忆爆炸问题**
- **云原生或其他场景扩展**：将框架扩展至云原生环境（如Kubernetes、容器）或物联网等新领域

渗透测试学习

漏洞测试基准

- **PENTESTGPT基准测试[PENTESTGPT_USENIX_2024]**：包括13个目标和182个子任务，涵盖OWASP十大漏洞以及常见弱点枚举(CWE)项目，基于这个基准，可以对LLM提供提示和目标机器信息，逐步生成渗透测试操作
- **PentestAgent基准测试[PENTESTGPT_USENIX_2024]**：选择vulhub：基于 docker-compose 的预构建易受攻击环境作为基准数据集，同时用漏洞评分系统(CVSS)了解漏洞利用的难度，并通过漏洞预测评分系统(EPSS)了解脆弱环境的现实程度，编制了一个包含67个渗透测试目标的基准

搭建DVWA环境

- **DVWA介绍**：包含数据 TOP10的所有攻击漏洞的练习环境，分别为 Low，Medium，High，Impossible，级别越高，安全防护越严格，渗透难度越大

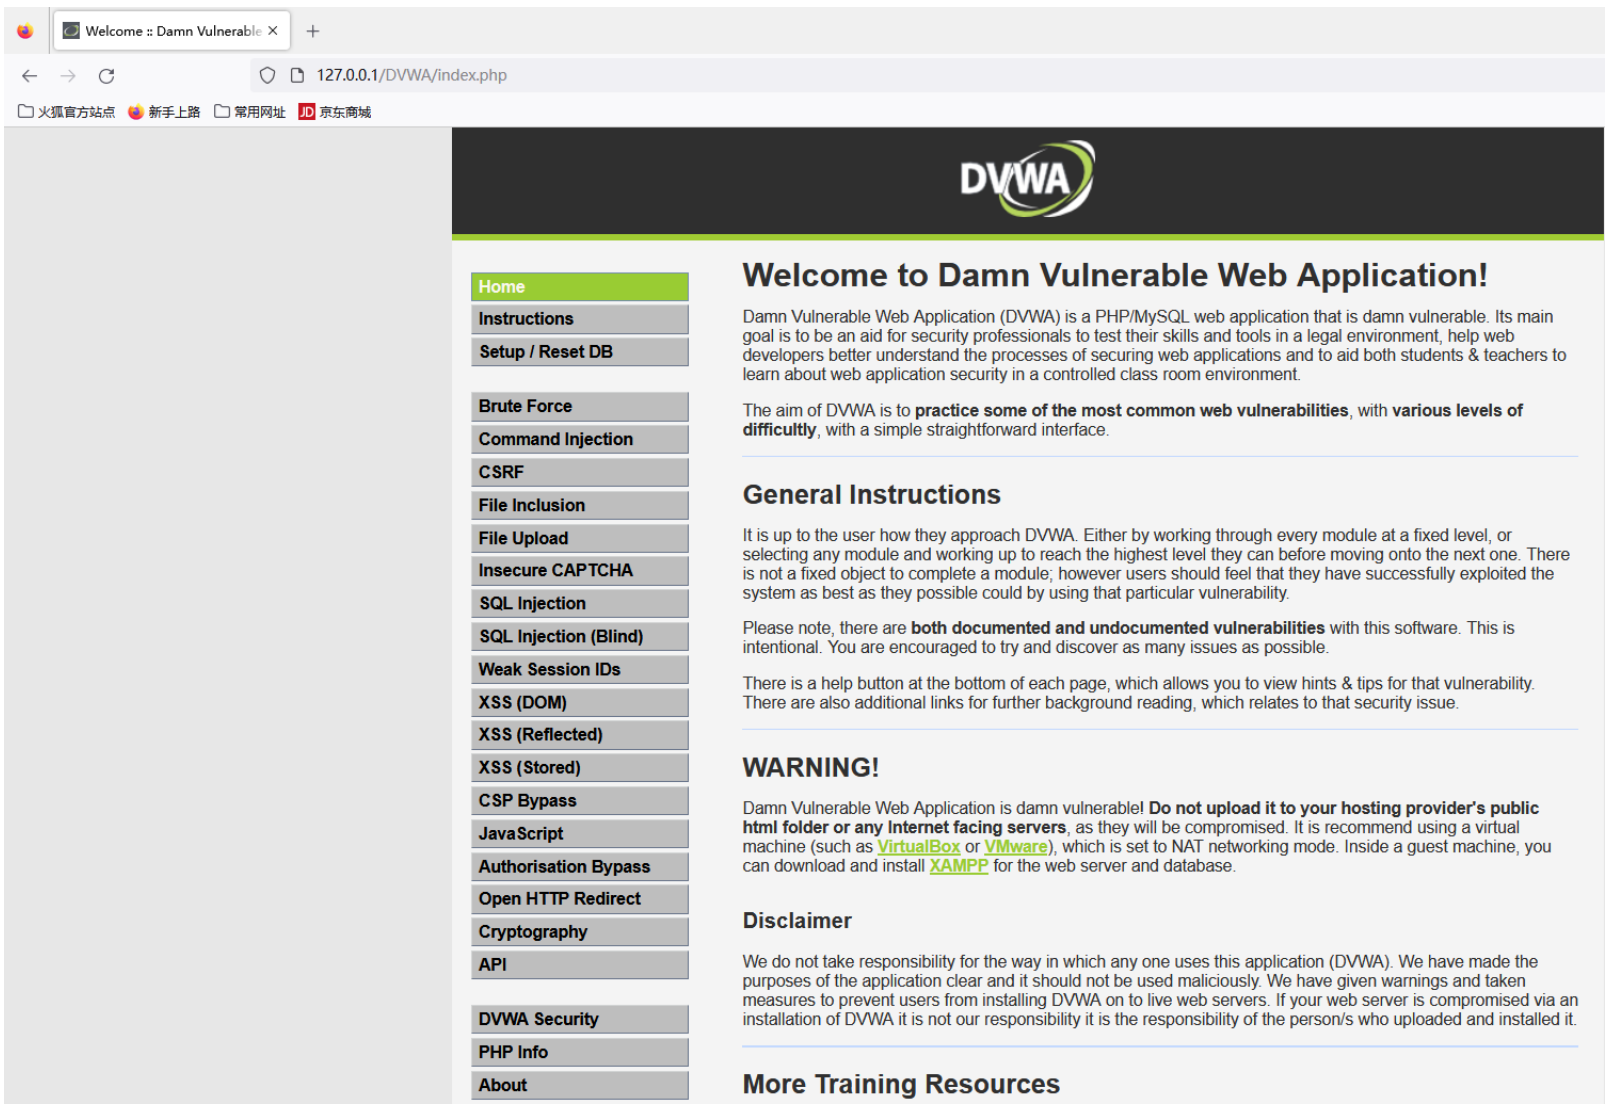

- **攻击模块**：包括不限于十个经典攻击模块，分别如下

攻击名称	特点	攻击方式
暴力破解Brute_Force	通过大量尝试破解认证凭证，依赖弱口令或默认配置	使用工具（如Hydra、Burp Suite）进行字典攻击或穷举
命令行注入 Command_Injection	注入操作系统命令，直接控制服务器	输入拼接恶意命令（如；`rm -rf /`或	`cat /etc/passwd`）
跨站请求伪造CSRF	利用用户已认证的会话，诱导执行非预期操作	构造恶意链接或表单（如`<img src="http://bank.com/transfer?to=attacker">`）
文件包含File_Inclusion	动态包含文件时未限制路径，分LFI（本地）和RFI（远程）	LFI：`../../etc/passwd`；RFI：包含远程恶意脚本（需`allow_url_include`开启）

攻击名称	特点	攻击方式
文件上传File_Upload	上传恶意文件到服务器并执行	绕过扩展名检查（如`.php5`）、伪造文件头（图片含PHP代码）
不安全的验证码 Insecure_CAPTCHA	验证码可被绕过或自动化破解，使暴力攻击有效	前端绕过（直接提交表单）、OCR识别简单验证码
SQL注入SQL_Injection	通过输入篡改SQL查询，直接操作数据库	输入`' OR '1'='1`绕过登录；`UNION SELECT`窃取数据
SQL盲注 SQL_Injection_(Blind)	无直接回显，通过布尔或时间延迟推断数据	布尔盲注：`AND 1=1`；时间盲注：`IF(1=1,SLEEP(5),0)`
反射型跨站脚本 XSS_(Reflected)	恶意脚本通过URL参数注入并即时反射，需用户点击触发	构造含JavaScript的URL（如`?search=<script>alert(1)</script>`）
存储型跨站脚本 XSS_(Stored)	恶意脚本存储到服务器（如评论），所有访问者自动执行	提交含脚本的内容（如`<script>stealCookie()</script>`）

- **反射型跨站脚本XSS_(Reflected)**：low级别的代码只是判断了**name参数是否为空**，如果不为空的话就直接打印出来，并没有对name参数做任何的过滤和检查，没用进行任何的对XSS攻击的防御措施，存在非常明显的XSS漏洞，用户输入什么都会被执行；

- 测试：用alert进行弹窗测试验证是否存在XSS，输入`<script>alert('hack')</script>`查看返回结果

- 结论：成功弹窗，说明存在XSS漏洞并且可利用，如获取cookie：编写一个`cookie.php`文档用于获取页面的`cookie`，放置在指定目录下