2025-04-10汇报

基于自主学习的大模型智能体自动化渗透测试研究

文献阅读=>AAAI_2024_ExpeL: LLM Agents Are Experiential Learners=>经验学习

研究目标

- **核心目标**：提出一种基于大模型智能体，通过**经验学习**（Experiential Learning）提升其在复杂交互任务中的性能，无需依赖模型参数微调
- **关键问题**：传统方法需高昂计算资源且可能损害模型泛化能力；且基于**提示（Prompting）**的方法受限于上下文窗口长度，无法跨任务积累经验
- **解决方案**：通过自主收集经验、提取自然语言知识，并在推理阶段动态结合历史经验和抽象知识，实现跨任务学习

研究对象

- **任务类型**：文本型复杂交互任务（如问答、在线购物、家庭环境决策等），涉及多步推理和工具调用（如搜索API）
- **智能体**：基于LLM的智能体（如ReAct、Reflexion），通过增强经验池（Experience Pool）和知识提取（Insight Extraction）提升性能
- **评估环境**：三个截然不同的包含确定性观察-动作序列的交互环境（如HotpotQA、ALFWorld、WebShop）

工作流程

- **经验收集（Experience Gathering）**
  - 使用**大模型Reflexion**，在训练任务中通过试错（Trial and Error）收集成功/失败轨迹，并形成**经验池**
  - 允许智能体在失败后通过**自我反思（Self-Reflection）**生成改进策略，并重新尝试任务
- **知识提取（Insight Extraction）**
  - 从经验池中提取自然语言知识（如"搜索物品时需考虑其用途"），支持**动态增删改查**
  - 通过对比成功与失败轨迹，总结**通用规则（Best Practices）**和**常见错误模式（Failure Patterns）**
- **任务推理（Task Inference）**
  - **知识增强**：将提取的**抽象知识（Insights）**拼接到任务指令中，指导LLM推理
  - **经验召回**：通过**向量检索（如Faiss）**从经验池中召回与当前任务最相关的成功轨迹，作为**上下文示例（In-Context Examples）**
- **迁移学习（Transfer Learning）**
  - 将源任务提取的知识通过少量目标任务示例进行适配（Finetune Insights），实现跨领域知识迁移

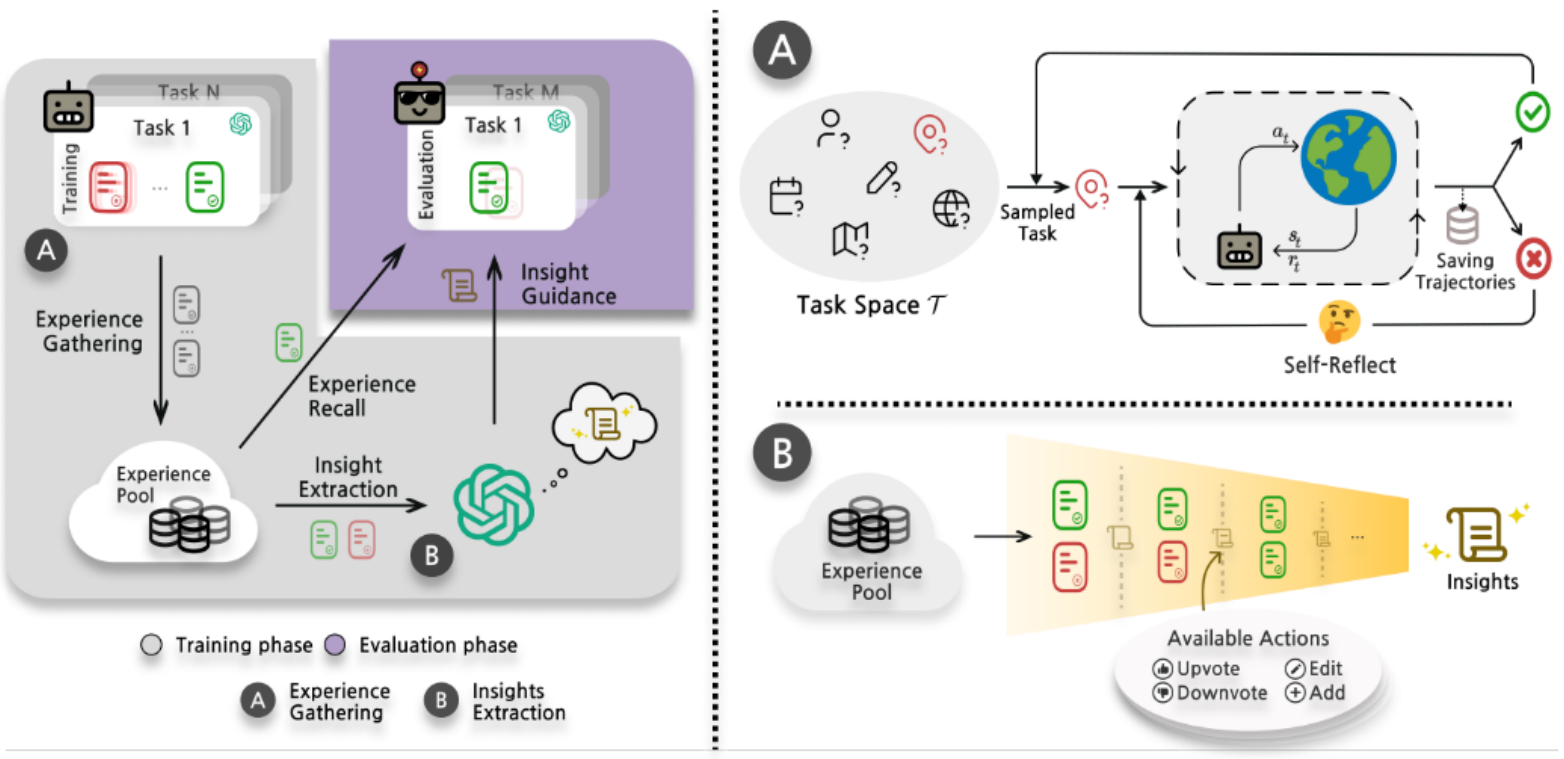

结合ExpeL与PentestAgent

研究目的

目标：通过LLM增强的多智能体协作，构建端到端的自动化渗透测试框架，减少人工参与，提升效率和成功率

- **解决现有问题=>LLM应用于渗透测试的挑战**：
  - **知识局限**：传统LLM**不具备**或**难以覆盖**渗透测试领域的专业知识
  - **短期记忆**：由于上下文窗口的限制，模型可能会忘记之前的操作，导致执行冗余的**重复任务**，无法**积累经验**
  - **自动化不足**：现有工具依赖人工干预，难以动态适应复杂环境（如防御机制变化）
  - **输出质量控制**：要求LLM以符合预定义标准或协议的结构化格式生成输出

流程设计

- **情报收集**：收集有关目标主机的环境信息，编译目标环境摘要，存储在环境信息数据库中
- **漏洞分析**：
  - **漏洞列表发现**：查询环境信息数据库以检索目标主机上暴露的服务和应用程序列表，利用**RAG技术**检索与提取**外部知识库**来查找潜在漏洞列表

    - **攻击计划制定**：提取**抽象知识（Insights）**并以**严格的JSON格式约束**生成任务指令，确定目标环境的合适漏洞利用以及攻击计划
- **渗透执行**：
    - **经验收集**：尝试在目标主机上执行攻击计划，在训练任务中通过试错（Trial and Error）收集成功/失败轨迹，并形成**经验池**
    - **知识增强**：允许智能体在失败后通过**自我反思（Self-Reflection）**生成改进策略，并重新尝试任务
    - **经验召回**：通过**向量检索（如Faiss）**从经验池中召回与当前任务最相关的成功轨迹，作为**上下文示例（In-Context Examples）**，同时记录全面的渗透测试报告

4. 实验设置

- **受害者机器**：在Ubuntu上运行模拟的易受攻击应用程序，禁用所有需要在端口上监听的服务，比如SSH
- **攻击者机器**：在Kali Linux上运行，包括Kali Linux中可用的所有预安装工具，没有安装其他工具
- **LLM模型**：使用Deepseek、GPT-3.5和GPT-4模型

两者通过**NAT**保持网络连接，在受害者机器上创建易受攻击的容器，并将网络参数设置为受害者机器的IP，允许攻击者机器直接访问受害者机器容器中托管的易受攻击环境

Vulhub测试环境搭建

- **环境搭建**：在**受害者端**Ubuntu 24上搭载**Vulhub**，进入某一个环境`flask/ssti`的目录`测试服务器端模板注入SSTI漏洞`，并进行编译与启动

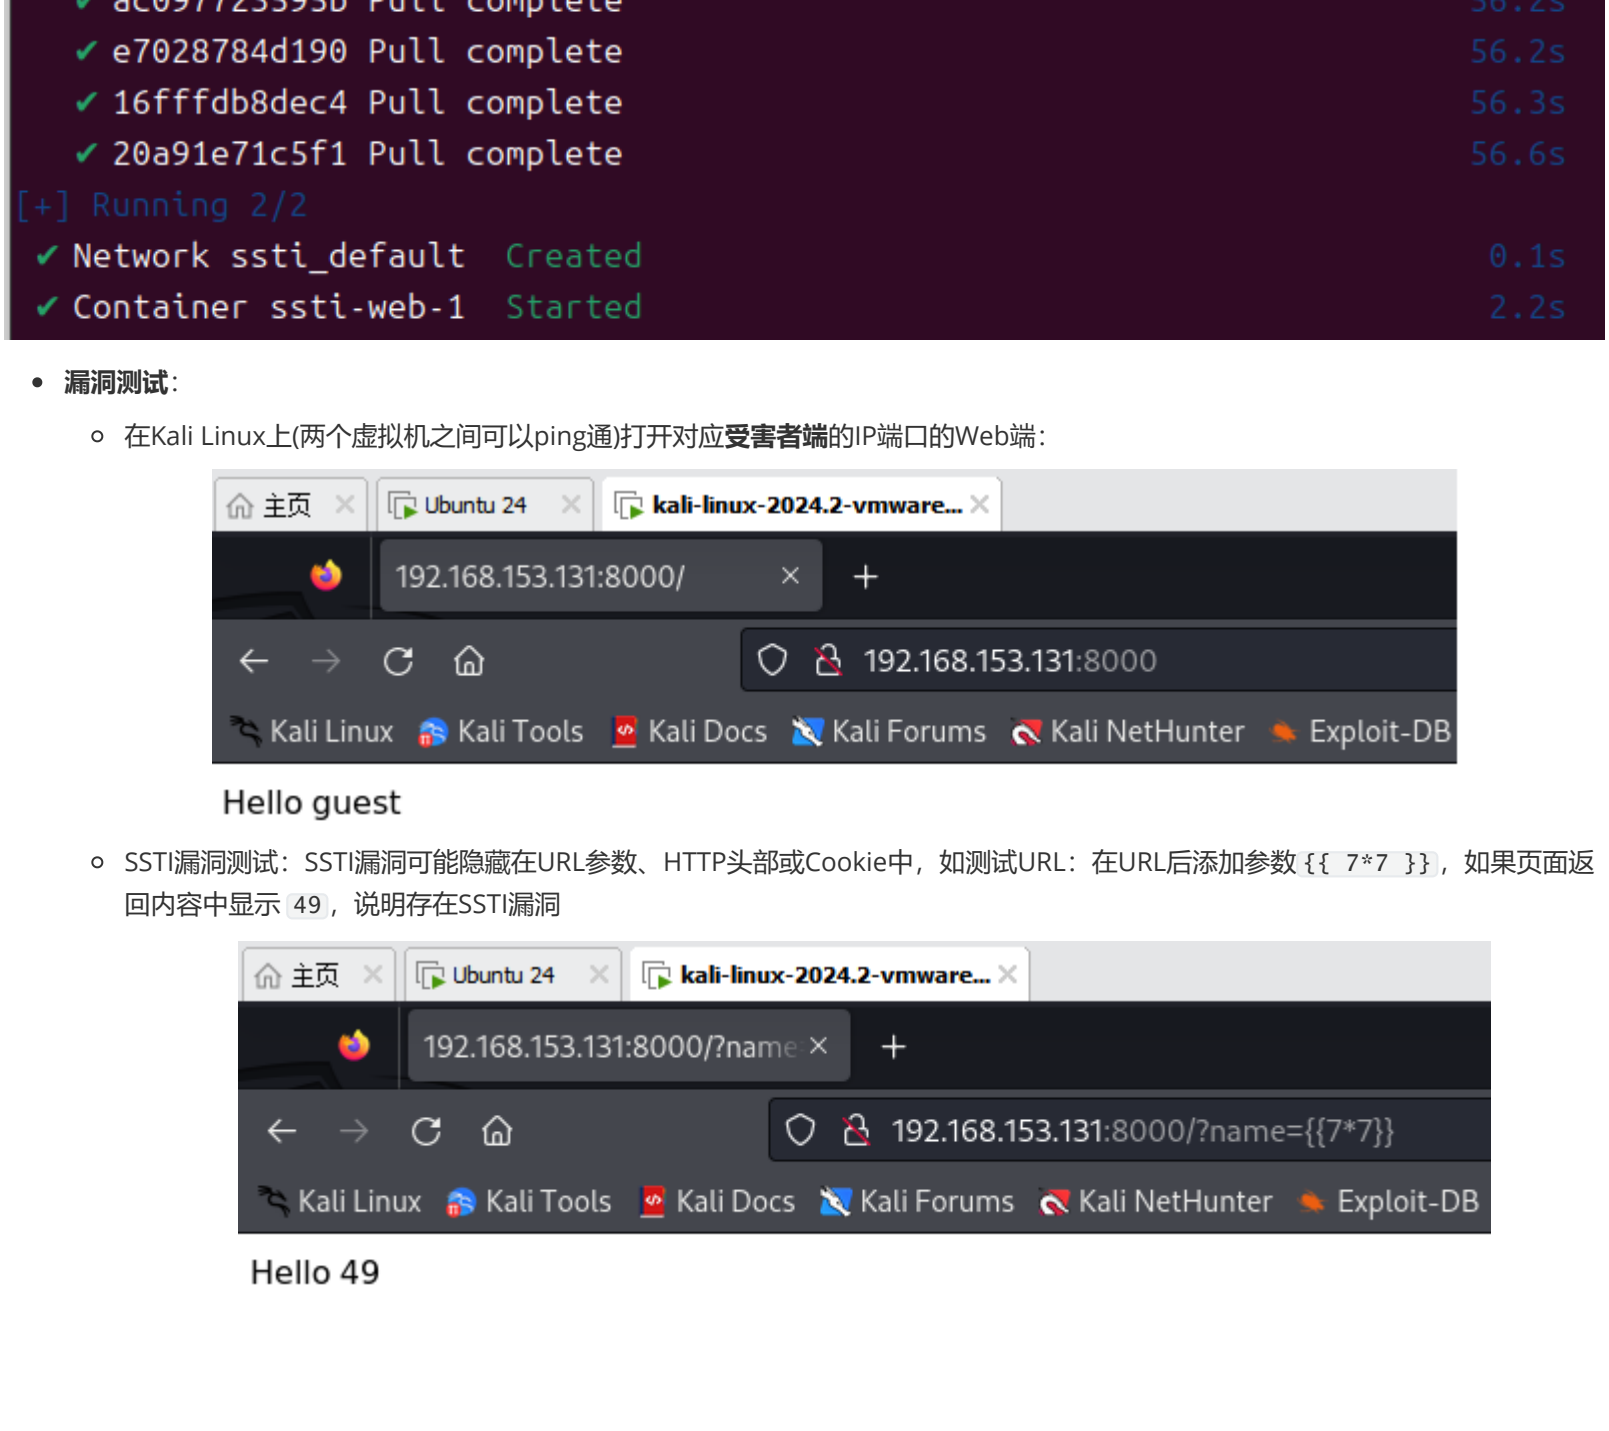

- **漏洞测试**：
    - 在Kali Linux上(两个虚拟机之间可以ping通)打开对应**受害者端**的IP端口的Web端：

    - SSTI漏洞测试：SSTI漏洞可能隐藏在URL参数、HTTP头部或Cookie中，如测试URL：在URL后添加参数`{{ 7*7 }}`，如果页面返回内容中显示`49`，说明存在SSTI漏洞

- 漏洞CVE-2023-4450——服务器端模板注入：**JimuReport** 是 JeecgBoot 项目下的开源可视化报表平台。在 1.6.0 之前的 JimuReport 版本中，**应用程序未对用户输入进行严格的验证和过滤**，存在能够执行任意命令的FreeMarker服务器端模板注入SSTI问题
- 发送以下请求以执行 FreeMarker 模板：`<#assign ex="freemarker.template.utility.Execute"?new()> ${ex("id")}`

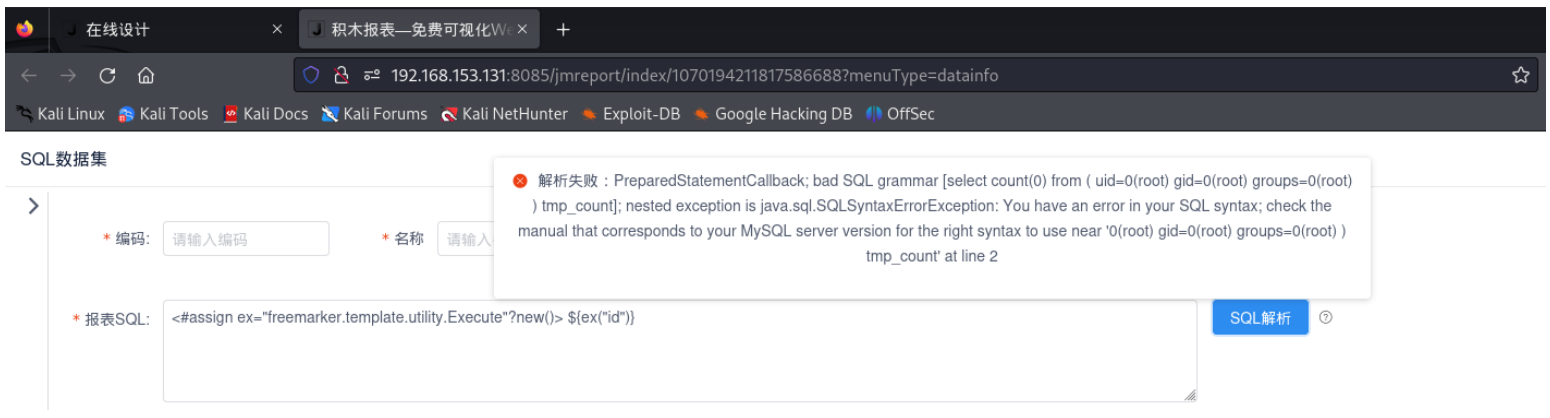

- 执行效果：创建了一个新的 `Execute` 对象，并将其赋值给变量 `ex`，执行命令 `id`，用于显示当前用户的身份信息，响应中可能会包含类似内容`uid=0(user) gid=0(user) groups=0(user)`，表明命令成功执行，并返回了当前用户的 UID、GID 和所属组 groups的信息

复现PentestAgent=>利用deepseek作为LLM首先进行CVE-2023-4450漏洞侦察

- 设置主题与目标主机IP：

```
recon_agent = ReconAgent()

curr_topic = "activemq_CVE-2023-4450"  # set chat thread topic to
target_ip = "192.168.153.131"         # set target IP for the reco
recon_init_message = f"I want to exploit target host {target_ip}"
logger.info(f"Starting reconnaissance on {curr_topic} \n\n")
recon_agent.init_thread(curr_topic)
```

- 将模型改为deepseek进行侦察：

```
class ReconAgent:
    #client = OpenAI()
    client = OpenAI(api_key="sk-892f217e45464d539afb8d4d9b7a1469", base_url="https://api.deepseek.com")
```

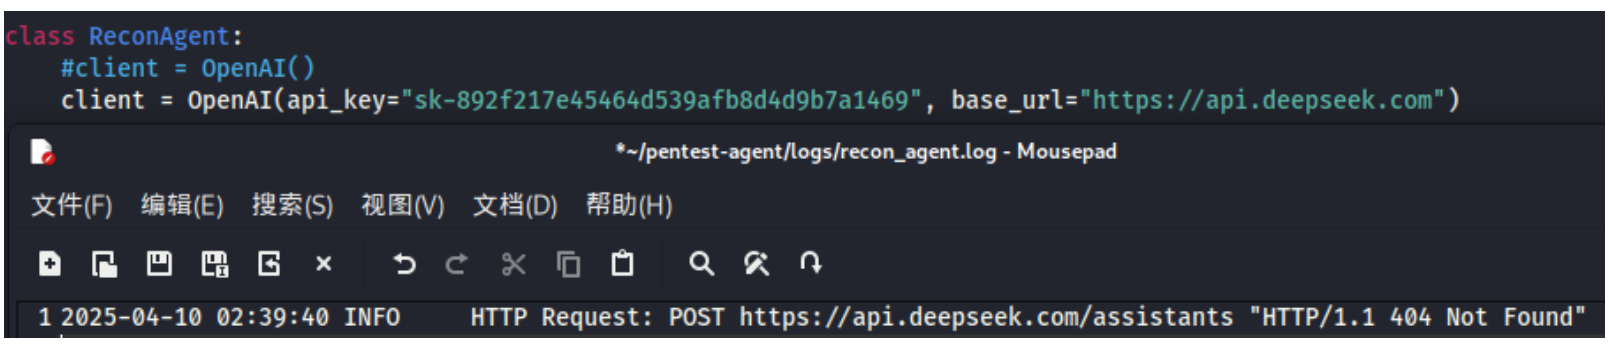

出现兼容性问题：OpenAI SDK 默认针对 OpenAI 的服务进行了优化，可能无法正确处理 DeepSeek 的 API 响应，调整中